

Aplicação de Modelos de Classificação para Detecção do Risco de Óbito em Pacientes com Insuficiência Cardíaca

Vitor José Ferreira dos Santos de Santana¹, Ericksulino Manoel de Araújo Mora¹

¹Universidade Federal do Piauí (UFPI)
Picos – PI – Brazil

Abstract. *This study addressed the prediction of mortality in patients with heart failure using machine learning algorithms and clinical data. The results demonstrated that it is possible to achieve good levels of accuracy, precision, and recall, highlighting the Random Forest model as the most effective, with an accuracy of 83.6%. The Artificial Neural Network (ANN) also showed satisfactory performance, although inferior, possibly due to the limited number of samples. The approach proved to be promising as a clinical decision support tool, potentially assisting in the early identification of patients at risk.*

Resumo. *Este trabalho abordou a predição de óbito em pacientes com insuficiência cardíaca por meio de algoritmos de aprendizado de máquina, utilizando dados clínicos. Os resultados demonstraram que é possível alcançar bons níveis de acurácia, precisão e recall, destacando o modelo Random Forest como o mais eficaz, com acurácia de 83.6%. A RNA também apresentou desempenho satisfatório, embora inferior, possivelmente devido ao número limitado de amostras. A abordagem mostrou-se promissora como ferramenta de apoio à decisão clínica, podendo auxiliar na identificação precoce de pacientes em risco.*

1. Introdução

Estima-se que 17,9 milhões de pessoas morreram de DCV em 2019, representando 32% de todas as mortes globais ¹. Doenças cardiovasculares, incluindo aterosclerose e insuficiência cardíaca, surgem da intrincada interação de desregulação metabólica, imunológica e neural nos tecidos vasculares e cardíacos [Anker et al. 2025]. A insuficiência cardíaca (IC) representa uma síndrome clínica complexa, que ocorre devido ao comprometimento funcional e estrutural do enchimento ventricular ou da ejeção do sangue [Heidenreich et al. 2022]. Ela continua sendo uma das principais causas globais de mortalidade, morbidade e baixa qualidade de vida (QV), com alto uso de recursos e custos de saúde [Savarese et al. 2022]. Os prontuários médicos eletrônicos disponíveis dos pacientes quantificam sintomas, características corporais e valores de exames laboratoriais clínicos, que podem ser usados para realizar análises bioestatísticas com o objetivo de destacar padrões e correlações que, de outra forma, seriam indetectáveis pelos médicos [Chicco and Jurman 2020].

Atualmente, a medicina tem utilizado a IA para aprimorar o diagnóstico, prognóstico e tratamento em diversas de suas áreas, como na neurologia, oncologia, cardiologia e dermatologia. Revelando, dessa forma, muitos benefícios para a saúde humana

¹[https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))

quando se trata de possibilitar uma maior precisão nas previsões da evolução da doença, na manutenção do desempenho dos tratamentos e nos menores riscos para o paciente [Braga et al. 2019]. Os casos da IC têm aumentado em todo o mundo, tanto entre jovens quanto entre adultos, e o número de mortes causadas por doenças cardiovasculares acende um alerta para os sistemas de saúde globalmente. Este trabalho tem como objetivo aplicar técnicas de aprendizado de máquina para prever a ocorrência de óbito durante o tratamento de pacientes diagnosticados com insuficiência cardíaca.

2. Referencial Teórico

Esta seção tem como finalidade apresentar os fundamentos teóricos que sustentam o desenvolvimento deste trabalho, abordando aspectos da insuficiência cardíaca, técnicas de aprendizado de máquina e redes neurais artificiais.

2.1. Insuficiência Cardíaca

A insuficiência cardíaca (IC) é uma síndrome clínica complexa, caracterizada pela incapacidade do coração de bombear sangue de forma adequada para suprir as necessidades metabólicas dos tecidos, ou pela necessidade de recorrer a elevadas pressões de enchimento para alcançar esse objetivo [da Silvia]. Esta condição pode ser provocada por alterações estruturais ou funcionais no coração, resultando em sinais e sintomas típicos decorrentes da redução no débito cardíaco e/ou do aumento das pressões de enchimento, tanto em repouso quanto durante o esforço físico [Braunwald et al. 2015]. De forma complementar, a IC pode ser definida como uma síndrome clínica que se manifesta por sintomas e/ou sinais de intolerância aos esforços e/ou retenção hídrica. Essas manifestações decorrem de disfunções cardíacas estruturais e/ou funcionais que levam à diminuição do débito cardíaco e/ou ao aumento das pressões intracardíacas [Ponikowski et al. 2016]. Frequentemente, a síndrome é deflagrada por um evento-índice, sendo a doença arterial coronariana e a hipertensão arterial sistêmica as causas mais prevalentes [da Silvia].

A gravidade da insuficiência cardíaca é evidenciada pelo seu caráter progressivo e pelas elevadas taxas de mortalidade, especialmente nas formas mais avançadas da doença [Bocchi et al. 1994, Velloso and Barretto 1996]. Além disso, trata-se de uma condição extremamente limitante, com impacto significativo na qualidade de vida dos pacientes [Stewart et al. 1989]. Embora a maioria dos quadros de IC envolva uma redução do débito cardíaco (IC de baixo débito), seja em repouso ou durante atividades físicas, existem também formas de IC com débito cardíaco elevado (IC de alto débito). Nesses casos, o coração é incapaz de suprir a demanda metabólica aumentada, como ocorre em situações clínicas específicas, como a tireotoxicose, anemia severa, fístulas arteriovenosas e o beribéri [da Silvia].

2.2. Classificadores

O Random Forest combina várias árvores de decisão aleatórias e agrega suas previsões por meio da média [Parmar et al. 2018]. O Random Forest verifica todos os resultados binários dessas árvores de decisões e escolhe seu resultado final por meio de uma votação majoritária. A classificação de recursos com base na precisão média diminui e conta o quanto a precisão da previsão diminui quando um recurso específico é removido. O método então compara essa precisão com a precisão obtida usando todos os recursos e considera essa diferença como a importância desse recurso específico: quanto maior a

queda na precisão, mais importante o recurso [Chicco and Jurman 2020]. O Gradient Boosting é uma técnica de aprendizado em conjunto que constrói modelos de forma sequencial, otimizando o desempenho ao corrigir os erros dos modelos anteriores. A ideia principal por trás desse algoritmo é construir os novos aprendizes de base para que sejam correlacionados ao máximo com o gradiente negativo da função de perda, associado a todo o conjunto [Natekin and Knoll 2013].

Bayes Naïve também é conhecido como um classificador probabilístico, pois se baseia no Teorema de Bayes ². O classificador Naive Bayes simplifica bastante o processo de aprendizado ao assumir que as variáveis (características) são independentes, dado a classe. Embora essa suposição de independência geralmente não seja realista, na prática o Naive Bayes frequentemente apresenta um desempenho comparável ao de classificadores mais sofisticados [Rish et al. 2001]. O classificador KNN serve para classificar observações não rotuladas, atribuindo-as à classe dos exemplos rotulados mais semelhantes. As características das observações são coletadas tanto para o conjunto de dados de treinamento quanto para o de teste. A escolha apropriada de k tem impacto significativo no desempenho diagnóstico do algoritmo KNN. Um k alto reduz o impacto da variância causada por erro aleatório, mas corre o risco de ignorar padrões pequenos, porém importantes [Zhang 2016]. Assim, ele classifica uma nova instância com base nas classes mais comuns entre seus vizinhos mais próximos no espaço de características. Neste trabalho foi atribuído o valor $k = 5$ para o cálculo do KNN.

2.3. Rede Neural Artificial

Redes Neurais Artificiais referem-se a sistemas de computação cujo tema central é emprestado da analogia das redes neurais biológicas. Redes Neurais Artificiais também são chamadas de "Redes Neurais", sistemas neurais artificiais, "sistemas de processamento distribuído paralelo" e "sistemas conexionistas" [Dongare et al. 2012]. Uma rede neural artificial consiste em unidades de processamento chamadas neurônios. Um neurônio artificial tenta replicar a estrutura e o comportamento do neurônio natural. Um neurônio consiste em entradas (dendritos) e uma saída (sinapse via axônio) [Kukreja et al. 2016]. A intenção é capturar as principais características importantes nas funções de processamento de informações de redes reais sem variar muito em relação às restrições físicas impostas pela biologia [Dongare et al. 2012].

A MLP (Multilayer Perceptron), ou Perceptron Multicamadas, é uma arquitetura de Rede Neural Artificial composta por uma ou mais camadas ocultas entre a camada de entrada e a de saída. Cada camada é formada por neurônios artificiais que utilizam funções de ativação não lineares, como a ReLU ou a sigmoid, permitindo à MLP aprender representações complexas e modelar relações não lineares entre as variáveis.

3. Trabalhos Relacionados

Foi realizado uma busca por artigos científicos publicados a partir de 2021 utilizando as palavras-chave "heart failure", "machine learning", "classification" e "death". O objetivo foi identificar estudos recentes que empregam técnicas de ML para prever mortalidade em pacientes com insuficiência cardíaca.

²<https://www.ibm.com/think/topics/naive-bayes>

[Gürfidan and Ersoy 2021] utilizou classificadores como Random Forest, KNN, Decision Tree, Naive Bayes e SVM para prever a mortalidade por insuficiência cardíaca, alcançando acurácia entre 73% e 83%. Já [Sarijaloo et al. 2021] propôs um modelo preditivo para readmissão ou óbito em até 90 dias após internação por IC, obtendo AUC de 0,760 e Recall de 83%. [Kyodo et al. 2023] aplicou o modelo variational Bayesian–Gaussian (VBGMM) para identificar três fenótipos clínicos em grupos de pacientes japoneses com insuficiência cardíaca com fração de ejeção preservada, com diferentes prognósticos em 5 anos. O grupo 1 apresentou o pior prognóstico (72,0%), seguido pelo grupo 2 (58,5%) e grupo 3 (45%).

[Smole et al. 2021] propôs uma ferramenta de estratificação de risco usando boosted trees para pacientes com cardiomiopatia hipertrófica, alcançando AUC de 0,82 e superando modelos anteriores. [Oladimeji and Oladimeji 2020] melhorou a predição de sobrevivência em pacientes com insuficiência cardíaca por meio da seleção de atributos relevantes e técnicas para tratar o desbalanceamento dos dados, utilizando classificadores com métricas como F-measure e AUC-ROC. [McGilvray et al. 2022] usou deep learning com dados de prontuários eletrônicos para prever não resposta à terapia, obtendo C-statistic de 0,91 em uma amostra com mais de 79 mil admissões.

A Tabela 1 apresenta um quadro comparativo entre os trabalhos relacionados citados. Enquanto a maioria dos trabalhos utiliza classificadores tradicionais e não explora redes neurais, apenas um deles aplica LSTM com dados temporais. Este trabalho se diferencia por incrementar a utilização da RNA para classificação de obitos por insuficiência cardíaca.

Tabela 1. Quadro comparativo de trabalhos relacionados

Trabalho	Métricas	Classificadores	Usa RNA
[Gürfidan and Ersoy 2021]	Acurácia	Random Forest KNN Decision Tree Naive Bayes SVM	Não
[Sarijaloo et al. 2021]	AUC e Recall	Regressão Logística	Não
[Kyodo et al. 2023]	Acurácia	Bayesian–Gaussian	Não
[Smole et al. 2021]	AUC	Boosted Trees	Não
[Oladimeji and Oladimeji 2020]	F-measure, AUC-ROC e curva de Precisão -Revocação.	Random Forest KNN Naive Bayes SVM	Não
[McGilvray et al. 2022]	C-statistic	LSTM	Sim
Este artigo	Acurácia Precisão Recall	KNN Naive Bayes Random Forest Gradient Boosting MLP	Sim

4. Metodologia

Esta seção apresenta a metodologia utilizada. Para realizar uma previsão da ocorrência de óbito de pacientes com insuficiência cardíaca, este trabalho utilizou uma abordagem

baseada em aprendizado de máquina supervisionado utilizando os classificadores Random Forest, Gradient Boosting, Naive Bayes, KNN, uma MLP e uma RNA.

4.1. Base de Dados

O conjunto de dados, *Heart Failure Clinical Records* ³, é composto por registros clínicos de 299 pacientes diagnosticados com insuficiência cardíaca, coletados entre abril e dezembro de 2015 no Instituto de Cardiologia de Faisalabad e no Hospital Allied, ambos localizados em Punjab, Paquistão. A população é formada por 105 mulheres e 194 homens, com idades variando entre 40 e 95 anos [Chicco and Jurman 2020]. Os dados estão organizados em uma tabela com 299 linhas (pacientes) e 13 colunas (características). As características incluem variáveis binárias como anemia, hipertensão, diabetes, sexo e tabagismo, além de variáveis numéricas como creatinina sérica, creatinina fosfoquinase, fração de ejeção, plaquetas, nível de sódio, tempo de acompanhamento, entre outras. A variável alvo, denominada "evento de morte", indica se o paciente faleceu (1) ou sobreviveu (0) antes do final do período de acompanhamento, cuja média é de 130 dias [Chicco and Jurman 2020].

4.2. Arquitetura da Rede Neural Artificial e MLP

A arquitetura da RNA foi construída utilizando o modelo sequencial da biblioteca *Keras*. Os dados foram divididos em conjuntos de treino e teste, com posterior normalização com a técnica de padronização (standardization) utilizando o *StandardScaler*. A rede possui uma camada de entrada compatível com o número de atributos do conjunto de dados, seguida por três camadas ocultas densamente conectadas: a primeira com 128 neurônios e Dropout de 40%, a segunda com 64 neurônios e Dropout de 30%, e a terceira com 32 neurônios — todas com função de ativação ReLU, que introduz não-linearidade ao modelo. A camada de saída contém um único neurônio com ativação sigmoide, adequada para problemas de classificação binária. A rede é treinada com o otimizador Adam e a função de perda *Binary Cross-Entropy*. O treinamento é realizado por 30 épocas com batch size de 16 e 30% dos dados de treinamento reservados para validação. A avaliação do modelo considera métricas como acurácia, precisão e recall, aplicadas sobre as previsões geradas no conjunto de teste.

A MLP foi implementada com o *MLPClassifier* da biblioteca *scikit-learn*, utilizando duas camadas ocultas com 128 e 64 neurônios. Os dados foram previamente normalizados com o *StandardScaler* e o treinamento foi realizado com até 1000 iterações e semente fixa para reprodutibilidade. A arquitetura aplica a função de ativação ReLU nas camadas ocultas e realiza previsões no conjunto de teste para avaliação do modelo.

5. Resultados

Este trabalho realizou uma classificação de previsão de morte por insuficiência cardíaca a partir de dados de pacientes paquistaneses coletados entre abril e dezembro de 2015. O conjunto de dados foi dividido em 70% para treino e 30% para teste. Para a avaliação dos resultados os modelos de classificação foram submetidos as métricas: Acurácia, Precisão e *Recall*. A acurácia é a razão entre o número total de observações que o modelo acertou e o número total de observações que o modelo previu [Junior et al. 2022]. A precisão denota a proporção de casos previstos como positivos que são realmente positivos

³<https://archive.ics.uci.edu/dataset/519/heart+failure+clinical+records>.

[Powers 2020]. O *recall* é a proporção de casos realmente positivos que são corretamente previstos como positivos [Powers 2020]. O processo de classificação repetido 5 vezes para garantir o cálculo de média dos valores de cada métrica e o desvio padrão das métricas, o que permite observar o comportamento do modelo durante várias interações e sua estabilidade entre os resultados. A Tabela 2 apresenta os resultados obtidos por cada classificador, seguindo o formato: média (\pm) desvio padrão.

Tabela 2. Métricas de desempenho dos classificadores (média \pm desvio padrão)

Métrica Classificador	Acurácia	Precisão	Recall
Random Forest	0.836 \pm 0.036	0.783 \pm 0.098	0.697 \pm 0.026
RNA	0.800 \pm 0.038	0.689 \pm 0.082	0.610 \pm 0.120
Gradient Boosting	0.798 \pm 0.011	0.710 \pm 0.040	0.641 \pm 0.047
Naive Bayes	0.791 \pm 0.013	0.781 \pm 0.048	0.497 \pm 0.056
MLP	0.762 \pm 0.035	0.646 \pm 0.063	0.600 \pm 0.068
KNN	0.613 \pm 0.029	0.293 \pm 0.112	0.172 \pm 0.102

O classificador Random Forest demonstrou o melhor desempenho, atingindo uma acurácia média de 0,836 ($\pm 0,036$), a maior precisão entre os modelos (0,783 \pm 0,098) e também o maior *recall* (0,697 \pm 0,026). A RNA montada para resolução deste trabalho apresentou um desempenho com acurácia de 0,80 ($\pm 0,038$), precisão de 0,689 ($\pm 0,082$) e *recall* de 0,610 ($\pm 0,120$). O Gradient Boosting também apresentou desempenho robusto, com acurácia de 0,798 ($\pm 0,011$), precisão de 0,710 ($\pm 0,040$) e *recall* de 0,641 ($\pm 0,047$). O classificador Naive Bayes obteve acurácia de 0,791 ($\pm 0,013$), precisão (0,781 \pm 0,048) e apresentou *recall* de (0,497 \pm 0,056). O modelo baseado em MLP alcançou acurácia de 0,762 ($\pm 0,035$), precisão de 0,646 ($\pm 0,063$) e *recall* de 0,600 ($\pm 0,068$). O K-Nearest Neighbors (KNN) teve o desempenho mais limitado, com acurácia de 0,613 ($\pm 0,029$), precisão de 0,293 ($\pm 0,112$) e *recall* de 0,172 ($\pm 0,102$).

6. Conclusão

Este trabalho realizou a classificação na previsão do óbito de pacientes com insuficiência cardíaca com base em dados clínicos. Os resultados indicam que é possível realizar essa predição com níveis relevantes de acurácia, precisão e recall, evidenciando o potencial do aprendizado de máquina para apoiar a tomada de decisão clínica. O modelo Random Forest se destacou como o mais eficaz para essa tarefa, apresentando a maior acurácia média. A alta precisão no conjunto de teste indica que a maior parte dos pacientes identificados como risco de óbito realmente pertencem a essa classe, reduzindo falsos positivos e o valor de recall sinaliza que o Random Forest consegue identificar uma proporção significativa dos pacientes que de fato vieram a óbito, tornando-se fundamental para que intervenções precoces sejam realizadas.

O modelo de RNA apresentou um bom desempenho o que sugere que é capaz de capturar bem os padrões associados ao óbito. No entanto, devido ao baixo número de amostras no dataset, pode ter influenciado o resultado inferior ao Random Forest. Assim, este trabalho mostra-se eficiente na abordagem de predição de óbito por insuficiência cardíaca, podendo ser uma ferramenta eficaz para alertar médicos e equipes clínicas sobre

pacientes que demandam maior atenção e cuidados intensificados. Para trabalhos futuros, sugere-se ampliar a base de dados, aprimorar a otimização dos modelos e investigar técnicas avançadas, incluindo interpretabilidade. Também é importante validar os modelos em diferentes contextos para aumentar sua confiabilidade.

Referências

- Anker, S. D., Karakas, M., Mentz, R. J., Ponikowski, P., Butler, J., Khan, M. S., Talha, K. M., Kalra, P. R., Hernandez, A. F., Mulder, H., et al. (2025). Systematic review and meta-analysis of intravenous iron therapy for patients with heart failure and iron deficiency. *Nature medicine*, pages 1–1.
- Bocchi, E. A. et al. (1994). Situação atual das indicações e resultados do tratamento cirúrgico da insuficiência cardíaca. *Arq Bras Cardiol*, 63(6):523–30.
- Braga, A. V., Lins, A. F., Soares, L. S., Fleury, L. G., Carvalho, J. C., and do Prado, R. S. (2019). Machine learning: o uso da inteligência artificial na medicina. *Brazilian Journal of Development*, 5(9):16407–16413.
- Braunwald, E., Mann, D. L., Zipes, D. P., Libby, P., and Bonow, R. (2015). Braunwald's heart disease: a textbook of cardiovascular medicine. In *Braunwald's heart disease: A textbook of cardiovascular medicine*, pages 1028–1028.
- Chicco, D. and Jurman, G. (2020). Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone. *BMC medical informatics and decision making*, 20:1–16.
- da Silvia, R. M. F. L. Insuficiência cardíaca: definição, epidemiologia, fisiopatologia e classificação.
- Dongare, A., Kharde, R., Kachare, A. D., et al. (2012). Introduction to artificial neural network. *International Journal of Engineering and Innovative Technology (IJEIT)*, 2(1):189–194.
- Gürfidan, R. and Ersoy, M. (2021). Classification of death related to heart failure by machine learning algorithms. *Advances in Artificial Intelligence Research*, 1(1):13–18.
- Heidenreich, P. A., Bozkurt, B., Aguilar, D., Allen, L. A., Byun, J. J., Colvin, M. M., Deswal, A., Drazner, M. H., Dunlay, S. M., Evers, L. R., et al. (2022). 2022 aha/acc/hfsa guideline for the management of heart failure: a report of the american college of cardiology/american heart association joint committee on clinical practice guidelines. *Journal of the American College of Cardiology*, 79(17):e263–e421.
- Junior, G. B. V., Lima, B. N., Pereira, A. A., Rodrigues, M. F., Oliveira, J. R. L., Silio, L. F., Carvalho, A. S., Ferreira, H. R., and Passos, R. P. (2022). Métricas utilizadas para avaliar a eficiência de classificadores em algoritmos inteligentes. *Revista CPAQV—Centro de Pesquisas Avançadas em Qualidade de Vida— Vol*, 14(2):2.
- Kukreja, H., Bharath, N., Siddesh, C., and Kuldeep, S. (2016). An introduction to artificial neural network. *Int J Adv Res Innov Ideas Educ*, 1(5):27–30.
- Kyodo, A., Kanaoka, K., Keshi, A., Nogi, M., Nogi, K., Ishihara, S., Kamon, D., Hashimoto, Y., Nakada, Y., Ueda, T., et al. (2023). Heart failure with preserved ejec-

- tion fraction phenogroup classification using machine learning. *ESC Heart Failure*, 10(3):2019–2030.
- McGilvray, M. M., Heaton, J., Guo, A., Masood, M. F., Cupps, B. P., Damiano, M., Pasque, M. K., and Foraker, R. (2022). Electronic health record-based deep learning prediction of death or severe decompensation in heart failure patients. *Heart Failure*, 10(9):637–647.
- Natekin, A. and Knoll, A. (2013). Gradient boosting machines, a tutorial. *Frontiers in neurorobotics*, 7:21.
- Oladimeji, O. O. and Oladimeji, O. (2020). Predicting survival of heart failure patients using classification algorithms. *JITCE (Journal of Information Technology and Computer Engineering)*, 4(02):90–94.
- Parmar, A., Katariya, R., and Patel, V. (2018). A review on random forest: An ensemble classifier. In *International conference on intelligent data communication technologies and internet of things*, pages 758–763. Springer.
- Ponikowski, P., Voors, A. A., Anker, S. D., Bueno, H., Cleland, J. G., Coats, A. J., Falk, V., González-Juanatey, J. R., Harjola, V.-P., Jankowska, E. A., et al. (2016). 2016 esc guidelines for the diagnosis and treatment of acute and chronic heart failure. *Polish Heart Journal (Kardiologia Polska)*, 74(10):1037–1147.
- Powers, D. M. (2020). Evaluation: from precision, recall and f-measure to roc, informedness, markedness and correlation. *arXiv preprint arXiv:2010.16061*.
- Rish, I. et al. (2001). An empirical study of the naive bayes classifier. In *IJCAI 2001 workshop on empirical methods in artificial intelligence*, volume 3, pages 41–46. Seattle, USA.
- Sarijaloo, F., Park, J., Zhong, X., and Wokhlu, A. (2021). Predicting 90 day acute heart failure readmission and death using machine learning-supported decision analysis. *Clinical cardiology*, 44(2):230–237.
- Savarese, G., Becher, P. M., Lund, L. H., Seferovic, P., Rosano, G. M., and Coats, A. J. (2022). Global burden of heart failure: a comprehensive and updated review of epidemiology. *Cardiovascular research*, 118(17):3272–3287.
- Smole, T., Žunkovič, B., Pičulin, M., Kokalj, E., Robnik-Šikonja, M., Kukar, M., Fotiadis, D. I., Pezoulas, V. C., Tachos, N. S., Barlocco, F., et al. (2021). A machine learning-based risk stratification model for ventricular tachycardia and heart failure in hypertrophic cardiomyopathy. *Computers in biology and medicine*, 135:104648.
- Stewart, A. L., Greenfield, S., Hays, R. D., Wells, K., Rogers, W. H., Berry, S. D., McGlynn, E. A., and Ware, J. E. (1989). Functional status and well-being of patients with chronic conditions: results from the medical outcomes study. *Jama*, 262(7):907–913.
- Velloso, L. G. C. and Barretto, A. C. P. (1996). Repercussão nutricional na miocardiopatia dilatada: estudo de indicadores do estado nutricional na insuficiência cardíaca em fase avançada.
- Zhang, Z. (2016). Introduction to machine learning: k-nearest neighbors. *Annals of translational medicine*, 4(11):218.